TP 2 — Docker Avancé, Cloud Run & Networking GCP

Cours 2 | Développer pour le Cloud | YNOV Campus Montpellier — Master 2

Date : 07/04/2026 | **Durée TP :** 3 h | **Plateforme :** Google Cloud Platform

```
Prérequis validés (Cours 1 ) :
```

```
Compte GCP actif, gcloud configuré
docker installé et fonctionnel
Application Flask tp1-app/ opérationnelle en local
```

Objectifs de ce TP :

```
Optimiser un Dockerfile avec le build multi-stage
Orchestrer une stack applicative avec Docker Compose (app + base de
données)
Pousser une image vers Google Artifact Registry
Déployer l'application sur Cloud Run
Configurer un VPC avec sous-réseaux et règles de pare-feu
```

Livrables attendus :

```
URL publique de votre application déployée sur Cloud Run (accessible
depuis internet)
Capture d'écran du terminal : docker images montrant la réduction de
taille (standard vs multi-stage)
Capture d'écran : service Cloud Run actif dans la console GCP
Fichier docker-compose.yml fonctionnel
README.md expliquant l'architecture et les commandes
```

Partie 1 — Docker Multi-Stage Build (30 min)

```
Le build multi-stage permet de séparer l'environnement de compilation de
l'environnement de production , réduisant
drastiquement la taille de l'image finale.
```

1.1 — Comprendre le problème

Commençons par mesurer la taille d'une image "naïve".

Créez un nouveau dossier tp2-app/ avec une application Node.js + TypeScript :

```
tp2-app/src/index.ts :
```

```
import express, { Request, Response } from 'express';

const app = express();
const PORT = parseInt(process.env.PORT || '8080', 10 );

app.get('/', (req: Request, res: Response) => {
res.json({
message: 'Hello from YNOV Cloud TP2',
version: '2.0.0',
stage: process.env.APP_ENV || 'production',
});
});

app.get('/health', (req: Request, res: Response) => {
res.status( 200 ).json({ status: 'ok' });

});

app.listen(PORT, '0.0.0.0', () => {
console.log(`Server running on port ${PORT}`);
});
```

tp2-app/package.json :

```
{
"name": "tp2-app",
"version": "2.0.0",
"scripts": {
"build": "tsc",
"start": "node dist/index.js",
"dev": "ts-node src/index.ts"
},
"dependencies": {
"express": "^4.18.2"
},
"devDependencies": {
"@types/express": "^4.17.21",
"@types/node": "^20.11.5",
"typescript": "^5.3.3"
```

```
}
}
```

tp2-app/tsconfig.json :

```
{
"compilerOptions": {
"target": "ES2020",
"module": "commonjs",
"outDir": "./dist",
"rootDir": "./src",
"strict": true,
"esModuleInterop": true
}
}
```

Dockerfile naïf (tp2-app/Dockerfile.naive) :

```
FROM node:20-alpine
WORKDIR /app
COPY package*.json ./
RUN npm install # Installe TOUTES les dépendances (y compris
devDependencies)
COPY . .
RUN npm run build
CMD ["node", "dist/index.js"]
```

```
cd tp2-app
# Builder l'image naïve
docker build -f Dockerfile.naive -t tp2-naive:v1 .
```

```
# Mesurer la taille
docker images tp2-naive:v
# Notez la taille : 201MB
```

1.2 — Dockerfile Multi-Stage

Maintenant créez le **vrai Dockerfile** (tp2-app/Dockerfile) avec deux stages :

```
# ==============================================
# Stage 1 : Build — Environnement de compilation
# ==============================================
```

```
FROM node:20-alpine AS build
WORKDIR /app

# Copier les fichiers de dépendances
COPY package*.json ./
COPY tsconfig.json ./

# Installer TOUTES les dépendances (y compris dev pour compiler
TypeScript)
RUN npm install

# Copier le code source TypeScript
COPY src/ ./src/

# Compiler TypeScript → JavaScript
RUN npm run build

# ==============================================
# Stage 2 : Runtime - Image de production minimale
# ==============================================
FROM node:20-alpine AS runtime
WORKDIR /app

# Copier uniquement package.json pour installer les dépendances de
PRODUCTION
COPY package*.json ./
RUN npm install --omit=dev # Flag pour exclure devDependencies

# Copier uniquement les fichiers compilés depuis le stage "build"
# Syntaxe : COPY --from=[NOM_STAGE] [SOURCE] [DEST]
COPY --from=build /app/dist ./dist

# Utilisateur non-root pour la sécurité
RUN addgroup -S appgroup && adduser -S appuser -G appgroup
USER appuser

EXPOSE 8080
ENV APP_ENV=production
ENV NODE_ENV=production

CMD ["node", "dist/index.js"]
```

```
# Builder l'image multi-stage
docker build -t tp2-app:v1 .

# Comparer les tailles
docker images | grep tp
# tp2-naive v1 ... 170MB
# tp2-app v1 ... 201MB
```

```
# Question : quelle est la réduction de taille en %?
# Calcul : (taille_naive - taille_multistage) / taille_naive * 100 =
____%
# Calcul valorisé : (201 - 170) / 201 * 100 = 15%
```

```
auguste@MacBook-Air-de-Auguste tp2-app % docker images | grep tp

WARNING: This output is designed for human readability. For machine-readable output, please use --format.
tp2-app:v1     35a1a0997ecf        170MB             0B
tp2-naive:v1   c2d7cc356522        201MB             0B
```

Question : Pourquoi les outils de build (TypeScript, gcc, etc.) ne doivent-ils **pas** être présents dans l'image de production ?

```
Réponse : On compile dans un stage build, puis on ne garde que le strict
nécessaire au runtime dans l'image finale.
```

1.3 — .dockerignore

Créez tp2-app/.dockerignore :

```
node_modules
dist
*.log
.env
.git # Exclure le dossier .git
*.md
Dockerfile*
docker-compose*
```

Partie 2 — Docker Compose : Stack App + PostgreSQL (30 min)

```
Docker Compose orchestre plusieurs conteneurs en local. On simule ici un
environnement de développement complet.
```

2.1 — Ajouter la connexion base de données

Modifiez tp2-app/src/index.ts pour ajouter une route /db :

```
import express, { Request, Response } from 'express';
import { Pool } from 'pg';

const app = express();
const PORT = parseInt(process.env.PORT || '8080', 10 );
```

```
// Pool de connexion PostgreSQL
const pool = new Pool({
host: process.env.DB_HOST || 'localhost',
port: parseInt(process.env.DB_PORT || '5432', 10 ),
database: process.env.DB_NAME || 'ynov_db',
user: process.env.DB_USER || 'ynov',
password: process.env.DB_PASSWORD || 'password',
});

app.get('/', (req: Request, res: Response) => {
res.json({ message: 'Hello from YNOV Cloud TP2', version: '2.1.0' });
});

app.get('/health', async (req: Request, res: Response) => {
try {

await pool.query('SELECT 1');
res.status( 200 ).json({ status: 'ok', database: 'connected' });
} catch (err) {
res.status( 503 ).json({ status: 'error', database: 'disconnected' });
}
});

app.get('/db', async (req: Request, res: Response) => {
try {
// Créer la table si elle n'existe pas et insérer une entrée
await pool.query(`
CREATE TABLE IF NOT EXISTS visits (
id SERIAL PRIMARY KEY,
visited_at TIMESTAMP DEFAULT NOW()
)
`);
await pool.query('INSERT INTO visits DEFAULT VALUES');
const result = await pool.query('SELECT COUNT(*) as total FROM visits');
res.json({ total_visits: parseInt(result.rows[ 0 ].total, 10 ) });
} catch (err) {
res.status( 500 ).json({ error: String(err) });
}
});

app.listen(PORT, '0.0.0.0', () => {
console.log(`Server listening on :${PORT}`);
});
```

Ajouter pg aux dépendances dans package.json :

```
# Dans le dossier tp2-app
npm install pg
npm install --save-dev @types/pg
```

2.2 — Écrire le fichier docker-compose.yml

Créez tp2-app/docker-compose.yml en complétant les blancs :

```
version: "3.9"

services:
  # Service applicatif Node.js
  web:
    build: .
    ports:
      - "8080:8080" # Mapper le port 8080 local vers le port 8080 du
conteneur
    environment:
      - APP_ENV=development
      - DB_HOST=db # Nom du service PostgreSQL (résolution DNS
automatique par Docker)
      - DB_PORT=5432
      - DB_NAME=ynov_db
      - DB_USER=ynov
      - DB_PASSWORD=secret_password
    depends_on:
      db:
        condition: service_healthy # Attendre que le healthcheck
PostgreSQL soit healthy
    networks:
      - app-network


# Service PostgreSQL
  db:
    image: postgres:16-alpine
    environment:
      - POSTGRES_DB=ynov_db
      - POSTGRES_USER=ynov
      - POSTGRES_PASSWORD=secret_password
    volumes:
      # Volume nommé pour la persistance des données
      - postgres-data:/var/lib/postgresql/data
    healthcheck:
      test: ["CMD-SHELL", "pg_isready -U ynov -d ynov_db"]
      interval: 5s
      timeout: 5s
      retries: 5
    networks:
      - app-network

# Définition des volumes nommés
volumes:
  postgres-data:
```

```
# Définition du réseau dédié
networks:
  app-network:
    driver: bridge
```

Question : Pourquoi utilise-t-on condition: service_healthy plutôt que condition: service_started pour depends_on?

```
Réponse : On utilise condition: service_healthy parce que le conteneur
PostgreSQL peut être démarré sans être encore prêt à accepter des
connexions. service_started ne garantit que le processus a lancé le
conteneur, pas que la base est initialisée, accessible et prête pour les
requêtes.

Avec service_healthy, Docker Compose attend que le healthcheck passe
avant de lancer le service web, ce qui évite les erreurs de démarrage
liées à une base pas encore disponible.
```

2.3 — Lancer et tester la stack

```
# Démarrer tous les services en arrière-plan
docker-compose up -d --build
# Sur Mac, j'ai dû spécifier que c'est un build Linux sinon GCP ne
l'accepte pas car c'est un build ARM64 par défaut sur Macos.
docker buildx build --platform linux/amd64 -t "${IMAGE}"
```

```
# Vérifier l'état des services (doivent être "running" et "healthy")
docker-compose ps
```

```
# Tester l'application
curl http://localhost:8080/
curl http://localhost:8080/health
curl http://localhost:8080/db # Premier appel → total_visits: 1
curl http://localhost:8080/db # Second appel → total_visits: 2
```

```
auguste@MacBook-Air-de-Auguste tp2-app % curl http://localhost:8080/

{"message":"Hello from YNOV Cloud TP2","version":"2.1.0"}%
auguste@MacBook-Air-de-Auguste tp2-app % curl http://localhost:8080/health

{"status":"ok","database":"connected"}%
auguste@MacBook-Air-de-Auguste tp2-app % curl http://localhost:8080/db
{"total_visits":1}%
auguste@MacBook-Air-de-Auguste tp2-app % curl http://localhost:8080/db
{"total_visits":2}%
```

```
# Voir les logs en temps réel
docker-compose logs -f
```

```
# Arrêter sans supprimer les volumes (données conservées)
docker-compose stop
```

```
# Arrêter ET supprimer les volumes (reset complet)
docker-compose down -v
```

Partie 3 — Artifact Registry & Push de l'Image (20 min)

```
Artifact Registry est le registry privé de GCP. Il remplace Container
Registry (gcr.io) et supporte Docker, Maven, npm,
Python, etc.
```

3.1 — Créer un repository Artifact Registry

Créer un repository Docker dans Artifact Registry
--repository-format=docker : type Docker
--location : région GCP

```
gcloud artifacts repositories create tp2-registry \
--repository-format=docker \
--location=europe-west9 \
--description="Registry TP2 YNOV"
```

```
# Lister les repositories existants
gcloud artifacts repositories list
```

3.2 — Authentifier Docker avec Artifact Registry

```
# Configurer Docker pour utiliser gcloud comme credential helper
# europe-west9-docker.pkg.dev est l'endpoint Artifact Registry pour
Paris
gcloud auth configure-docker europe-west9-docker.pkg.dev
```

```
# Vérifier la configuration dans ~/.docker/config.json
cat ~/.docker/config.json | grep -A3 "credHelpers"
```

3.3 — Tagger et pousser l'image

```
# Format du tag pour Artifact Registry :
# [REGION]-docker.pkg.dev/[PROJECT_ID]/[REPOSITORY]/[IMAGE]:[TAG]

PROJECT_ID=$(gcloud config get-value project)
IMAGE_TAG="europe-west9-docker.pkg.dev/${PROJECT_ID}/tp2-registry/tp2-
app:v1"

echo "Image tag : ${IMAGE_TAG}"

# Tagger l'image locale avec le format Artifact Registry
docker tag tp2-app:v1 ${IMAGE_TAG}

# Pousser l'image
docker push ${IMAGE_TAG}

# Vérifier que l'image est bien dans le registry
gcloud artifacts docker images list \
europe-west9-docker.pkg.dev/${PROJECT_ID}/tp2-registry
```

Partie 4 — Déploiement sur Cloud Run (20 min)

```
Cloud Run est le service PaaS serverless de GCP pour les conteneurs. Il
scale automatiquement de 0 à N instances
selon le trafic, et vous ne payez qu'à l'usage.
```

4.1 — Déployer le service

```
PROJECT_ID=$(gcloud config get-value project)
IMAGE="europe-west9-docker.pkg.dev/${PROJECT_ID}/tp2-registry/tp2-
app:v1"
```

```
gcloud run deploy tp2-service \
--image=${IMAGE} \
--region=europe-west9 \
--platform=managed \
--allow-unauthenticated \
--port=8080 \
--memory=512Mi \
--cpu=1 \
--max-instances=3 \
--set-env-vars="APP_ENV=production"

# La commande retourne une URL publique du type :
# https://tp2-service-xxxxxxxxxx-ew.a.run.app
# Mon URL: https://tp2-service-622615739189.europe-west9.run.app
```

```
Note : Cloud Run ne peut pas se connecter directement à votre PostgreSQL
local. Pour ce TP, le service /db
retournera une erreur de connexion — ce n'est pas un problème. On
utilisera Cloud SQL en cours 4.
```

4.2 — Tester le déploiement

```
# Récupérer l'URL du service
SERVICE_URL=$(gcloud run services describe tp2-service \
--region=europe-west9 \
--format='value(status.url)')
```

```
echo "URL du service : ${SERVICE_URL}"
```

```
# Tester les endpoints
curl https://tp2-service-zowztgcaaq-od.a.run.app/
OU
curl ${SERVICE_URL}

curl https://tp2-service-zowztgcaaq-od.a.run.app/health
OU
curl ${SERVICE_URL}/health
```

```
# Vérifier les informations du service
gcloud run services describe tp2-service --region=europe-west9
```

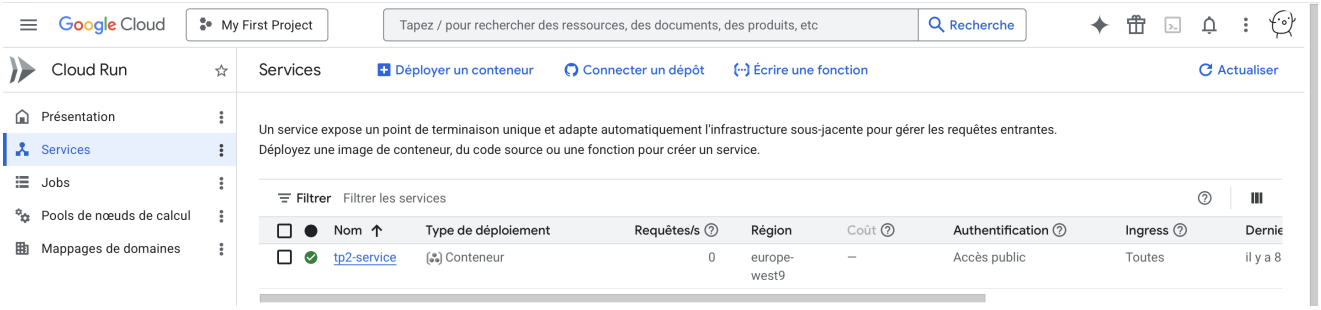

Question : Quelle est la différence entre --max-instances=3 et --min-instances=1 dans Cloud Run?

```
Réponse :
--max-instances=3 fixe le plafond: Cloud Run ne créera jamais plus de 3
instances, même en pic de trafic (protection coût/ressources, mais
risque de latence / erreur 429 si surcharge).
--min-instances=1 fixe le plancher: Cloud Run garde au moins 1 instance
toujours démarrée, même sans trafic (moins de cold start, mais coût
permanent minimal).
```

4.3 — Observer le comportement de scale à zéro

```
# Ne pas envoyer de requêtes pendant 5 minutes, puis relancer
# Cloud Run réduit les instances à 0 après inactivité (cold start)
```

```
# Mesurer le temps de réponse après inactivité
time curl ${SERVICE_URL}/health
```

```
# Question : Combien de ms pour le premier appel (cold start)?
# Réponse : Commande qui n'a pas marché pour moi, vu ensemble en cours.
Plus lent, en général autour de 800 à 3000 ms.
```

```
# Combien de ms pour les appels suivants (warm)?
# Réponse : Commande qui n'a pas marché pour moi, vu ensemble en cours.
Plus rapide, souvent autour de 50 à 300 ms.
```

Partie 5 — Networking GCP : VPC & Firewall (20 min)

```
GCP crée un VPC "default" automatiquement. Pour des déploiements
professionnels, on crée son propre VPC avec des
sous-réseaux isolés.
```

5.1 — Créer un VPC personnalisé

```
# Créer un VPC en mode custom (pas de sous-réseaux automatiques)
gcloud compute networks create tp2-vpc \
--subnet-mode=custom # custom ou auto?

# Créer un sous-réseau public (pour les services exposés à internet)
gcloud compute networks subnets create tp2-subnet-public \
--network=tp2-vpc \
--region=europe-west9 \
--range=10.10.1.0/24 # Utiliser le bloc CIDR 10.10.1.0/

# Créer un sous-réseau privé (pour les bases de données, non exposé)
gcloud compute networks subnets create tp2-subnet-private \
--network=tp2-vpc \
--region=europe-west9 \
--range=10.10.2.0/24
```

Question : Pourquoi sépare-t-on les ressources applicatives et les bases de données dans des sous-réseaux différents?

```
Réponse :
On les sépare surtout pour la sécurité et le contrôle réseau.

- Sécurité: la base de données n'a pas besoin d'être exposée à Internet,
donc on la met en sous-réseau privé.
- Isolation: si la partie applicative est compromise, la base reste
mieux protégée.
- Règles firewall plus fines: on autorise seulement les flux nécessaires
(ex: app -> DB sur 5432).
- Bonne pratique d'architecture: séparation des rôles, plus simple à
auditer et à faire évoluer.
```

5.2 — Règles de pare-feu (Firewall Rules)

```
# Règle 1 : Autoriser le trafic HTTP (port 80) depuis internet vers le
sous-réseau public
gcloud compute firewall-rules create tp2-allow-http \
--network=tp2-vpc \
--direction=INGRESS \
```

```
--action=ALLOW \
--rules=tcp:80 \
--source-ranges=0.0.0.0/0 \
--target-tags=http-server
```

```
# Règle 2 : Autoriser le trafic HTTPS (port 443)
gcloud compute firewall-rules create tp2-allow-https \
--network=tp2-vpc \
--direction=INGRESS \
--action=ALLOW \
--rules=tcp:443 \
--source-ranges=0.0.0.0/0 \
--target-tags=http-server
```

```
# Règle 3 : Autoriser PostgreSQL (port 5432) UNIQUEMENT depuis le sous-
réseau applicatif
gcloud compute firewall-rules create tp2-allow-postgres \
--network=tp2-vpc \
--direction=INGRESS \
--action=ALLOW \
--rules=tcp:5432 \
--source-ranges=10.10.1.0/24 \
--target-tags=db-server
```

```
# Lister les règles de firewall du VPC
gcloud compute firewall-rules list --filter="network=tp2-vpc"
```

```
auguste@MacBook-Air-de-Auguste tp2-app % gcloud compute firewall-rules list --filter="network=tp2-vpc"

NAME                NETWORK  DIRECTION  PRIORITY  ALLOW     DENY  DISABLED
tp2-allow-http      tp2-vpc  INGRESS    1000      tcp:80          False
tp2-allow-https     tp2-vpc  INGRESS    1000      tcp:443         False
tp2-allow-postgres  tp2-vpc  INGRESS    1000      tcp:5432        False
```

Question : Quelle est la différence entre un Security Group (AWS) et une Firewall Rule (GCP)?

```
Réponse :
AWS: tu raisonnes d'abord "à qui est attaché ce Security Group ?".
GCP: tu raisonnes d'abord "quelle règle VPC s'applique à ce trafic et à
quelles cibles (tags/SA) ?".
```

5.3 — Nettoyage du VPC

```
# Supprimer dans l'ordre inverse (les règles avant le VPC)
gcloud compute firewall-rules delete tp2-allow-http --quiet
gcloud compute firewall-rules delete tp2-allow-https --quiet
gcloud compute firewall-rules delete tp2-allow-postgres --quiet
gcloud compute networks subnets delete tp2-subnet-public --
region=europe-west9 --quiet
gcloud compute networks subnets delete tp2-subnet-private --
region=europe-west9 --quiet
gcloud compute networks delete tp2-vpc --quiet

echo "Nettoyage VPC terminé"
```

Partie 6 — Cloud Storage Avancé : Versioning & Lifecycle (20 min)

```
En production, on ne supprime jamais accidentellement des fichiers. Le
versioning et les règles de lifecycle protègent les données et
optimisent les coûts.
```

6.1 — Bucket avec versioning activé

```
PROJECT_ID=$(gcloud config get-value project)
BUCKET="ynov-tp2-versioned-${PROJECT_ID}"

# Créer un bucket avec versioning activé dès la création
gcloud storage buckets create gs://${BUCKET} \
--location=europe-west9 \
--uniform-bucket-level-access # Contrôle d'accès unifié (recommandé)

# Activer le versioning sur le bucket
gcloud storage buckets update gs://${BUCKET} \
--versioning # Flag pour activer le versioning

# Vérifier
gcloud storage buckets describe gs://${BUCKET} \
--format="value(versioning.enabled)"
# Résultat attendu : True
```

6.2 — Tester le versioning

```
# Créer et uploader un fichier
echo "Version 1 - $(date)" > config.json
gcloud storage cp config.json gs://${BUCKET}/
```

```
# Modifier et uploader une nouvelle version
echo "Version 2 - $(date)" > config.json
gcloud storage cp config.json gs://${BUCKET}/
```

```
# Uploader une 3ème version
echo "Version 3 - $(date)" > config.json
gcloud storage cp config.json gs://${BUCKET}/
```

```
# Lister TOUTES les versions (y compris les anciennes)
gcloud storage ls -a gs://${BUCKET}/config.json
```

```
# Question : combien de versions voyez-vous?
# Réponse : 3
```

```
# Lire une ancienne version via son génération (numéro affiché dans ls -
a)
# gcloud storage cp "gs://${BUCKET}/config.json#1775557831470979"
./config_v1.json
```

6.3 — Règles de lifecycle automatisées

```
# Créer un fichier de règles lifecycle (JSON)
cat > lifecycle.json << 'EOF'
{
  "lifecycle": {
    "rule": [
      {
        "action": { "type": "Delete" },
        "condition": {
          "numNewerVersions": 3,
          "isLive": false
        }
      },
      {
        "action": {
          "type": "SetStorageClass",
          "storageClass": "NEARLINE"
        },
        "condition": {
          "age": 30,
```

```
          "isLive": true
        }
      }
    ]
  }
}
```

```
# Appliquer les règles lifecycle au bucket
gcloud storage buckets update gs://${BUCKET} \
--lifecycle-file=lifecycle.json
```

```
# Vérifier les règles appliquées
gcloud storage buckets describe gs://${BUCKET} \
--format="json(lifecycle)"
```

Question : Expliquez les deux règles lifecycle configurées ci-dessus. Quel est l'intérêt économique de passer en classe NEARLINE après 30 jours?

```
Règle 1 : supprimer les versions non actives (isLive: false) dès qu'il
existe plus de 3 versions plus récentes (numNewerVersions: 3).
Cela limite l'accumulation d'anciennes versions et évite de payer du
stockage inutile.

Règle 2 : pour les objets actifs (isLive: true) âgés de plus de 30 jours
(age: 30), changer la classe de stockage en NEARLINE.
Cela garde les données accessibles, mais en classe "archive légère"
moins chère.

Intérêt économique : NEARLINE réduit le coût de stockage des données peu
consultées.
Tu paies moins cher au mois pour stocker, avec un compromis:
accès/récupération un peu plus coûteux que STANDARD.
```

6.4 — Nettoyage

```
# Supprimer TOUTES les versions (y compris les non-live)
gcloud storage rm -r --all-versions gs://${BUCKET}
```

Partie 7 — Cloud Run Avancé : Révisions & Traffic Splitting (20 min)

```
Cloud Run gère des révisions (snapshots immuables d'un déploiement). On
peut router le trafic entre plusieurs
révisions pour des déploiements progressifs.
```

7.1 — Déployer une nouvelle révision

On simule une mise à jour applicative en changeant une variable d'environnement (sans changer le code).

```
PROJECT_ID=$(gcloud config get-value project)
IMAGE="europe-west9-docker.pkg.dev/${PROJECT_ID}/tp2-registry/tp2-
app:v1"

# Déployer une "v2" avec une variable d'environnement différente
# --no-traffic : la nouvelle révision ne reçoit PAS de trafic
immédiatement
gcloud run deploy tp2-service \
--image=${IMAGE} \
--region=europe-west9 \
--no-traffic \
--set-env-vars="APP_ENV=production,APP_VERSION=2.0.0" \
--tag=v2 # Tag pour identifier cette révision

# Lister les révisions
gcloud run revisions list \
--service=tp2-service \
--region=europe-west9
```

7.2 — Traffic Splitting (déploiement Canary)

```
# Router 80% du trafic vers la révision stable, 20% vers la nouvelle
# Récupérer les noms des 2 dernières révisions
REV_STABLE=$(gcloud run revisions list \
--service=tp2-service --region=europe-west9 \
--format="value(name)" | sed -n '2p') # 2ème = ancienne
```

```
REV_CANARY=$(gcloud run revisions list \
```

```
--service=tp2-service --region=europe-west9 \
--format="value(name)" | sed -n '1p') # 1ère = dernière (canary)
```

```
echo "Stable : ${REV_STABLE}"
echo "Canary : ${REV_CANARY}"
```

```
# Diviser le trafic : 80% stable, 20% canary
gcloud run services update-traffic tp2-service \
--region=europe-west9 \
--to-revisions="${REV_STABLE}=_______,${REV_CANARY}=_______"
```

```
# Vérifier la répartition du trafic
gcloud run services describe tp2-service \
--region=europe-west9 \
--format="yaml(status.traffic)"
```

7.3 — Tester la répartition

```
SERVICE_URL=$(gcloud run services describe tp2-service \
--region=europe-west9 --format='value(status.url)')
```

```
# Envoyer 10 requêtes et observer quelle version répond
for i in $(seq 1 10); do
curl -s ${SERVICE_URL}/ | python3 -c "import sys,json;
d=json.load(sys.stdin);
print(d.get('stage','?'))"
done
```

```
# Question : sur 10 requêtes, combien environ ont reçu
APP_VERSION=2.0.0?
# Résultat observé :
# Explication mathématique (20% de 10 requêtes) :
```

7.4 — Basculer 100 % vers la nouvelle révision (promotion)

```
# Après validation : envoyer 100% du trafic vers la canary
gcloud run services update-traffic tp2-service \
--region=europe-west9 \
--to-latest
```

```
# Vérifier
gcloud run services describe tp2-service \
--region=europe-west9 \
--format="yaml(status.traffic)"
```

Question : Pourquoi le traffic splitting est-il préférable à un redéploiement direct (--to-latest immédiat) en production
?

```
Réponse :
```

Partie 8 — Docker Compose : Ajouter un Cache Redis (20 min)

```
Les applications cloud utilisent souvent un cache en mémoire pour
réduire la charge sur la base de données et
accélérer les réponses.
```

8.1 — Ajouter Redis au docker-compose.yml

Modifiez tp2-app/docker-compose.yml pour ajouter un service Redis :

```
# Ajouter ce service après "db:"
cache:
image: redis:_______-alpine # Utiliser la version 7
command: redis-server --maxmemory 128mb --maxmemory-policy allkeys-lru
ports:
```

- "6379:6379"
  healthcheck:
  test: ["CMD", "redis-cli", "ping"]
  interval: 5s
  timeout: 3s
  retries: 3
  networks:
- app-network

Ajouter la variable d'environnement Redis dans le service web :

```
environment:
```

- REDIS_HOST=_____ # Nom du service cache
- REDIS_PORT=

Et ajouter la dépendance :

```
depends_on:
db:
condition: service_healthy
_______: # Dépendre aussi du service cache
condition: service_healthy
```

8.2 — Ajouter la route /cached dans l'application

Ajoutez dans src/index.ts :

```
import { createClient } from 'redis';
```

```
const redisClient = createClient({
socket: {
host: process.env.REDIS_HOST || 'localhost',
port: parseInt(process.env.REDIS_PORT || '6379', 10 ),
},
});
```

```
redisClient.connect().catch(console.error);
```

```
app.get('/cached', async (req: Request, res: Response) => {
const CACHE_KEY = 'visit_count_cached';
const TTL_SECONDS = 10 ;
```

```
try {
// Lire depuis le cache Redis
const cached = await redisClient.get(CACHE_KEY);
```

```
if (cached !== null) {
return res.json({
total_visits: parseInt(cached, 10 ),
source: _______, // "cache" si lu depuis Redis
```

```
ttl_remaining: await redisClient.ttl(CACHE_KEY),
});
}
```

```
// Cache miss : lire depuis PostgreSQL
const result = await pool.query('SELECT COUNT(*) as total FROM visits');
const count = parseInt(result.rows[ 0 ].total, 10 );
```

```
// Stocker dans Redis avec TTL de 10 secondes
await redisClient.setEx(CACHE_KEY, TTL_SECONDS, String(count));
```

```
return res.json({
total_visits: count,
source: _______, // "database" si lu depuis PostgreSQL
});
} catch (err) {
return res.status( 500 ).json({ error: String(err) });
}
});
```

Installer le client Redis :

```
# redis v4+ inclut ses propres types TypeScript — @types/redis n'existe
plus
npm install redis
```

8.3 — Tester le cache

```
docker-compose up -d --build
```

```
# Première requête → source: "database" (cache froid)
curl http://localhost:8080/cached
```

```
# Requêtes suivantes dans les 10 secondes → source: "cache"
curl http://localhost:8080/cached
curl http://localhost:8080/cached
```

```
# Attendre 11 secondes et relancer → source: "database" (cache expiré)
sleep 11 && curl http://localhost:8080/cached
```

```
# Question : quel est l'intérêt du TTL (Time-To-Live) dans un cache?
# Réponse :
```

Question : Dans quelle situation l'utilisation d'un cache Redis peut-elle poser un **problème de cohérence** des données?

```
Réponse :
```

Nettoyage Final

```
# Supprimer le service Cloud Run
gcloud run services delete tp2-service --region=europe-west9 --quiet
```

```
# Supprimer le repository Artifact Registry (et toutes les images)
gcloud artifacts repositories delete tp2-registry \
--location=europe-west9 --quiet
```

```
# Vérification
gcloud run services list --region=europe-west
gcloud artifacts repositories list --location=europe-west
```

Récapitulatif — Compétences validées

```
Docker multi-stage build (réduction de taille d'image)
Docker Compose avec PostgreSQL et Redis (stack multi-services)
Google Artifact Registry (push et gestion d'images)
Cloud Run (déploiement, révisions, traffic splitting canary)
VPC + Subnets + Firewall Rules GCP
Cloud Storage versioning et règles lifecycle
Cache Redis avec TTL et gestion de la cohérence
```

Pour le Cours 3 (28/04/2026)

```
Repository Git complet avec Dockerfile, docker-compose.yml et README
URL Cloud Run de l'application déployée (preuve de déploiement)
Journal des commandes exécutées avec les résultats
Installer kubectl : gcloud components install kubectl
Installer terraform :
https://developer.hashicorp.com/terraform/downloads
```